

# Business Requirements Document (BRD)

## NORA — Network Oracle for Reliable Answers

|                |                                                                             |
|----------------|-----------------------------------------------------------------------------|
| Produk         | NORA — Network Oracle for Reliable Answers                                  |
| Tipe           | SaaS — Platform AI Research Engine multi-topik untuk standar telekomunikasi |
| Kolaborasi     | NOZ (Telecom Security Research) × PT Arah Karya Sinergi                     |
| Versi dokumen  | 0.2 (Draft)                                                                 |
| Tanggal        | Juni 2026                                                                   |
| Disiapkan oleh | Hermes Arah (ArahKarya)                                                     |
| Status         | Draft — menunggu review                                                     |

### 1. Ringkasan Eksekutif

NORA adalah **platform AI Research Engine berbasis RAG** yang menjawab pertanyaan teknis seputar standar telekomunikasi dengan jawaban **tergrounded pada spec resmi** — bukan halusinasi. Setiap jawaban disertai **skor keyakinan (confidence)** dan **referensi sumber** (nomor section spec).

NORA dirancang **multi-topik**: tiap **Topik** adalah knowledge base independen (mis. 3GPP TS 24.008, 3GPP TS 23.501, ITU-T, IEEE 802.x, GSMA) dengan metode RAG yang **identik**. User memilih Topik sebelum bertanya, dan sistem mengarahkan query ke knowledge base Topik tersebut. **Topik pertama** yang diimplementasi & terbukti adalah **3GPP TS 24.008** (reference implementation).

Berbeda dengan chatbot LLM umum yang menjawab dari ingatan dan rawan ngarang, NORA memakai arsitektur **RAG + dual-model (Generator → Verifier) + validation layer**, diorkestrasi oleh **Hermes Agent** sebagai otak eksekusi.

**Engine default:** API cloud via **9router (Claude Opus generator + Sonnet verifier)**. **Mode lokal:** dapat di-swap ke **Ollama** tanpa mengubah arsitektur — privacy-first opsional.

#### Proposisi Nilai Inti

- Anti-halusinasi** — jawaban wajib bersumber dari spec resmi.
- Self-validating** — model kedua memverifikasi jawaban model pertama sebelum dikirim.
- Auditable** — setiap jawaban punya confidence score + sumber yang bisa ditelusuri.
- Multi-topik & extensible** — satu engine RAG, banyak knowledge base; nambah Topik baru tanpa ubah arsitektur.
- Engine-agnostic** — cloud (Opus/Sonnet) atau lokal (Ollama), satu arsitektur.

## 2. Latar Belakang & Masalah

### 2.1 Masalah

Engineer telco harus membaca **ribuan halaman** spec 3GPP (mis. TS 24.008 ~600+ halaman, ratusan versi rilis) untuk menjawab satu pertanyaan teknis. Proses ini:

- Lambat dan melelahkan (cari manual di PDF/.doc).
- Rawan salah interpretasi antar versi rilis.
- Tidak ter-dokumentasi (jawaban hilang setelah cari).

### 2.2 Kenapa bukan ChatGPT/LLM biasa

LLM umum menjawab dari **parametric memory** → sering **halusinasi** pada detail teknis (nomor section, IE, prosedur). Untuk domain regulasi/standar, ini **tidak dapat diterima** — jawaban salah bisa berdampak pada desain jaringan.

### 2.3 Solusi

NORA mengingesti **spec resmi** (per Topik) ke vector database, lalu menjawab dengan retrieval + sintesis + verifikasi. Sumber jawaban selalu spec asli, bukan ingatan model. Topik pertama yang diimplementasi adalah 3GPP TS 24.008; Topik lain (3GPP spec lain, ITU-T, IEEE, GSMA, dst.) menyusul dengan metode yang sama.

## 3. Tujuan & Sasaran

### 3.1 Tujuan Bisnis

- **G1** — Menyediakan tool riset spec telco yang akurat & cepat untuk engineer.
- **G2** — Menjadi showcase kapabilitas RAG-reliable kolab NOZ x ArahKarya.
- **G3** — Arsitektur reusable **multi-topik**: satu engine RAG melayani banyak knowledge base standar telco, mudah ditambah Topik baru.

### 3.2 Sasaran Terukur (MVP)

| ID    | Sasaran                           | Target                                                       |
|-------|-----------------------------------|--------------------------------------------------------------|
| OBJ-1 | Jawaban tergrounded dengan sumber | 100% jawaban menyertakan $\geq 1$ sumber                     |
| OBJ-2 | Latensi query standar             | < 10 detik (cloud Opus)                                      |
| OBJ-3 | Coverage knowledge base           | Seluruh versi TS 24.008 (257 rilis) terindeks                |
| OBJ-4 | Hallucination guard               | Jawaban tanpa dukungan konteks → ditolak/flag LOW CONFIDENCE |

### 3.3 Non-Tujuan (Out of Scope MVP)

- **Domain non-telco** (mis. medis, hukum) — fokus standar telekomunikasi dulu. (Multi-**topik** dalam telco justru inti desain MVP.)
- Fine-tuning model.

- Real-time spec update otomatis (Fase lanjut via cron).
- Mobile native app (web dulu).

## 4. Stakeholder & Pengguna

| Peran         | Pihak                   | Kepentingan                         |
|---------------|-------------------------|-------------------------------------|
| Owner produk  | NOZ + ArahKarya         | Arah produk & strategi              |
| Domain expert | NOZ (Tri Sumarno)       | Validasi akurasi telco, sumber spec |
| Engineering   | ArahKarya (Hermes Arah) | Build, deploy, maintain             |
| End user      | Network/telco engineer  | Query spec, riset teknis            |

### Persona Utama

"**Network Engineer**" — paham telco, butuh jawaban cepat & akurat dari spec. Akses via dashboard web / chat. Tidak mau baca 600 halaman manual.

## 4A. Konsep Topik (Multi-Topic Knowledge Base)

NORA adalah **engine RAG generik** yang melayani banyak knowledge base. Tiap knowledge base disebut **Topik**.

### Definisi

**Topik** = satu domain/spec standar telco yang punya knowledge base sendiri, collection vector sendiri, namun **berbagi metode RAG yang sama** (chunking section-aware → embed → retrieve → generate → verify → validate).

### Struktur Topik

| Atribut    | Contoh (Topik pertama)                  | Keterangan                |
|------------|-----------------------------------------|---------------------------|
| id         | 3gpp-ts24008                            | ID teknis unik            |
| nama       | 3GPP TS 24.008                          | Nama tampil ke user       |
| deskripsi  | Mobile radio interface L3; MM/GMM/CC/SM | Ringkasan domain          |
| collection | ts24008                                 | Nama collection ChromaDB  |
| kb_dir     | data/3gpp/24008/txt                     | Lokasi knowledge base     |
| status     | live                                    | live / indexing / planned |

### Topik Roadmap (ilustrasi)

| Topik                 | Status                                      | Catatan                |
|-----------------------|---------------------------------------------|------------------------|
| <b>3GPP TS 24.008</b> | ● <b>Live</b> (topik pertama, terbukti E2E) | NAS L3 — MM/GMM/CC/SM  |
| 3GPP TS 23.501        | ○ Planned                                   | 5G System Architecture |
| 3GPP TS 33.501        | ○ Planned                                   | 5G Security            |

| Topik            | Status    | Catatan                    |
|------------------|-----------|----------------------------|
| ITU-T (seri Q/X) | ◦ Planned | Signalling & data networks |
| IEEE 802.x       | ◦ Planned | LAN/Wireless               |
| GSMA / O-RAN     | ◦ Planned | Operator & open RAN        |

## Alur Multi-Topik

1. User **memilih Topik** (dropdown/menu) sebelum bertanya.
2. Query diarahkan ke **collection** milik Topik tersebut.
3. Pipeline RAG identik berjalan dalam scope Topik itu.
4. Admin bisa **menambah Topik baru**: daftarkan metadata → ingest knowledge base → Topik siap dipakai. **Tanpa ubah kode engine.**

Nilai bisnis: satu codebase, banyak produk. Tiap Topik baru = penambahan pasar (segmen engineer berbeda) dengan biaya marginal rendah.

## 5. Kebutuhan Fungsional

Notasi: **MUST** (wajib MVP), **SHOULD** (sebaiknya), **COULD** (opsional lanjut).

### 5.1 Knowledge Ingestion

| ID         | Requirement                                                                                                       | Prioritas |
|------------|-------------------------------------------------------------------------------------------------------------------|-----------|
| FR-ING-001 | Sistem <b>MUST</b> mengingesti dokumen spec (.txt hasil convert .doc/.docx 3GPP)                                  | MUST      |
| FR-ING-002 | Sistem <b>MUST</b> chunk dokumen berbasis <b>section number</b> (mis. "4.1.2 ATTACH REQUEST"), bukan ukuran fixed | MUST      |
| FR-ING-003 | Sistem <b>MUST</b> generate embedding tiap chunk & simpan ke vector DB                                            | MUST      |
| FR-ING-004 | Tiap chunk <b>MUST</b> menyimpan metadata: spec ID, versi rilis, section, judul                                   | MUST      |
| FR-ING-005 | Sistem <b>SHOULD</b> dukung delta ingestion (hanya versi baru)                                                    | SHOULD    |
| FR-ING-006 | Sistem <b>COULD</b> generate hash (Keccak-256) per dokumen untuk provenance                                       | COULD     |

### 5.2 Query & Retrieval (RAG)

| ID         | Requirement                                                                                            | Prioritas |
|------------|--------------------------------------------------------------------------------------------------------|-----------|
| FR-RAG-001 | Sistem <b>MUST</b> embed query user lalu retrieve top-K chunk relevan (default K=5, cosine similarity) | MUST      |
|            | Sistem <b>MUST</b> inject konteks retrieved ke prompt sebelum generate                                 | MUST      |

| ID         | Requirement                                                                 | Prioritas |
|------------|-----------------------------------------------------------------------------|-----------|
| FR-RAG-002 |                                                                             |           |
| FR-RAG-003 | Sistem SHOULD dukung filter versi rilis (mis. "jawab berdasarkan R16 saja") | SHOULD    |
| FR-RAG-004 | Sistem SHOULD dukung query lintas-versi (bandingkan antar rilis)            | SHOULD    |

### 5.3 Dual-Model Reasoning (Generator + Verifier)

| ID        | Requirement                                                                                     | Prioritas |
|-----------|-------------------------------------------------------------------------------------------------|-----------|
| FR-MM-001 | Generator (Opus via 9router) MUST hasilkan jawaban awal dari konteks                            | MUST      |
| FR-MM-002 | Verifier (Opus via 9router) MUST cek jawaban vs konteks, klasifikasi: VALID / PARTIAL / INVALID | MUST      |
| FR-MM-003 | Jika INVALID, sistem MUST regenerate dengan prompt termodifikasi (loop, maks N=2)               | MUST      |
| FR-MM-004 | Engine MUST swappable: 9router (default) ↔ Ollama (lokal) via config                            | MUST      |

### 5.4 Validation Layer

| ID        | Requirement                                                      | Prioritas |
|-----------|------------------------------------------------------------------|-----------|
| FR-VL-001 | Sistem MUST cross-check klaim jawaban vs chunk sumber            | MUST      |
| FR-VL-002 | Sistem MUST tolak/flag jawaban dengan klaim tak didukung sumber  | MUST      |
| FR-VL-003 | Sistem MUST hitung confidence score 0-1                          | MUST      |
| FR-VL-004 | Jika confidence < 0.7, jawaban MUST diberi flag "LOW CONFIDENCE" | MUST      |

### 5.5 Output

| ID         | Requirement                                                                             | Prioritas |
|------------|-----------------------------------------------------------------------------------------|-----------|
| FR-OUT-001 | Output MUST terstruktur: <code>{answer, confidence, sources[], verifier_verdict}</code> | MUST      |
| FR-OUT-002 | Sources MUST sebut spec ID + versi + section number                                     | MUST      |
| FR-OUT-003 | UI SHOULD render jawaban + sumber yang bisa di-expand ke teks asli                      | SHOULD    |

### 5.6 Orkestrasi (Hermes Agent — embedded core)

| ID         | Requirement                                                                         | Prioritas |
|------------|-------------------------------------------------------------------------------------|-----------|
| FR-ORC-001 | Hermes MUST jadi orchestration core: retrieve → generate → verify → validate → loop | MUST      |
| FR-ORC-002 | Hermes MUST dipanggil sebagai service/library internal oleh backend (opsi 5a)       | MUST      |
| FR-ORC-003 | Hermes SHOULD delegate query kompleks lintas-versi ke subagent paralel              | SHOULD    |
| FR-ORC-004 | Hermes SHOULD simpan konteks riset (memory) per user/sesi                           | SHOULD    |
| FR-ORC-005 | Hermes COULD jadwalkan auto-reindex spec via cron                                   | COULD     |

## 5.7 SaaS Platform (Multi-user)

| ID          | Requirement                                                            | Prioritas |
|-------------|------------------------------------------------------------------------|-----------|
| FR-SAAS-001 | Sistem MUST punya auth (login/register)                                | MUST      |
| FR-SAAS-002 | Sistem MUST log tiap query (query, konteks, jawaban, hasil validasi)   | MUST      |
| FR-SAAS-003 | Sistem SHOULD kumpulkan feedback user (correct/incorrect/partial)      | SHOULD    |
| FR-SAAS-004 | Sistem SHOULD pakai feedback untuk perbaiki ranking retrieval & prompt | SHOULD    |
| FR-SAAS-005 | Sistem COULD dukung role (admin/engineer/viewer)                       | COULD     |

## 5.8 Topik (Multi-Topic Management)


| ID         | Requirement                                                                           | Prioritas |
|------------|---------------------------------------------------------------------------------------|-----------|
| FR-TOP-001 | Sistem MUST punya registry Topik (id, nama, deskripsi, collection, kb_dir, status)    | MUST      |
| FR-TOP-002 | User MUST memilih Topik sebelum query; query MUST diarahkan ke collection Topik tsb   | MUST      |
| FR-TOP-003 | Sistem MUST isolasi data antar-Topik (retrieval tidak bocor lintas-Topik)             | MUST      |
| FR-TOP-004 | Admin MUST bisa menambah Topik baru (daftar metadata + ingest) tanpa ubah kode engine | MUST      |
| FR-TOP-005 | Sistem SHOULD tampilkan daftar Topik + status (live/indexing/planned) ke user         | SHOULD    |
| FR-TOP-006 | Sistem COULD dukung query lintas-Topik (mis. cari di 3GPP + ITU-T sekaligus)          | COULD     |

## 6. Kebutuhan Non-Fungsional

| ID      | Kategori        | Requirement                                                             |
|---------|-----------------|-------------------------------------------------------------------------|
| NFR-001 | Performa        | Query standar < 10 detik (cloud), < 30 detik (lokal Ollama RPi5)        |
| NFR-002 | Skalabilitas    | ≥ 10 concurrent user (MVP)                                              |
| NFR-003 | Privacy         | Mode lokal (Ollama): tidak ada call eksternal; data tetap di host       |
| NFR-004 | Reliability     | Fallback graceful: 9router down → fallback model / Ollama lokal         |
| NFR-005 | Keamanan        | Akses remote via Cloudflare Tunnel (tanpa port terbuka); secret di .env |
| NFR-006 | Maintainability | Containerized (Docker Compose); config-driven engine swap               |
| NFR-007 | Auditability    | Setiap jawaban traceable ke sumber + tersimpan di log                   |

## 7. Arsitektur Sistem (High-Level)





## Data Flow (1 query)

1. User kirim query (dashboard/Telegram)
2. Backend → Hermes core
3. Hermes: embed query → ChromaDB retrieve top-5 chunk
4. Hermes: bangun prompt [Sys][Context][Query] → Generator (Opus)
5. Hermes: jawaban → Verifier (Opus) → VALID/PARTIAL/INVALID
6. Jika INVALID → loop ke step 4 (maks 2x)
7. Validation layer: cross-check + confidence score
8. Output {answer, confidence, sources} → backend → user
9. Log interaksi + (opsional) feedback

## 8. Stack Teknologi

| Layer         | Komponen  | Pilihan                             | Alasan                           |
|---------------|-----------|-------------------------------------|----------------------------------|
| Frontend      | Dashboard | Next.js + Tailwind                  | SSR, modern, cepat               |
| Backend       | API       | FastAPI (Python)                    | Async, cocok untuk AI pipeline   |
| Orkestrasi    | Agent     | <b>Hermes Agent</b> (embedded)      | Memory, skills, subagent, loop   |
| LLM (default) | Cloud     | <b>9router → Claude Opus</b>        | Reasoning kuat untuk verifikasi  |
| LLM (swap)    | Lokal     | Ollama (Llama3.1/Qwen)              | Privacy-first opsional           |
| Vector store  | DB        | ChromaDB                            | Ringan, embedded, cocok RPi5/VPS |
| Embedding     | Model     | 9router embed / nomic-embed-text    | Sesuai mode cloud/lokal          |
| Parsing       | Doc→Text  | LibreOffice headless (sudah teruji) | Convert .doc 3GPP → .txt         |
| Auth          | -         | JWT / session                       | Multi-user SaaS                  |

| Layer  | Komponen | Pilihan                    | Alasan                     |
|--------|----------|----------------------------|----------------------------|
| Deploy | Infra    | Docker Compose + CF Tunnel | Containerized, remote aman |

## 9. Knowledge Base — Topik #1: 3GPP TS 24.008 (Status Saat Ini)

NORA multi-topik; berikut status **Topik pertama** (reference implementation). Topik lain menyusul dengan struktur sama.

| Item            | Status                                                                  |
|-----------------|-------------------------------------------------------------------------|
| Spec target     | TS 24.008 — Mobile radio interface L3; Core network protocols; Stage 3  |
| Cakupan isi     | Mobility Mgmt (MM), GPRS MM (GMM), Call Control (CC), Session Mgmt (SM) |
| Versi terkumpul | <b>257 rilis</b> (R98 v3.0.0 → R18 j-series), 1999–2026                 |
| Format mentah   | .doc/.docx (per zip) — <b>778 MB</b>                                    |
| Format diolah   | .txt via LibreOffice headless                                           |
| Lokasi          | <code>~/data/3gpp/24008/{zip,doc,txt}</code>                            |
| Status convert  | Sedang berjalan (background)                                            |

## 10. Roadmap (Fase)

### Fase 1 — RAG Core (Fondasi)

- Chunking per-section + embedding seluruh TS 24.008
- Index ke ChromaDB dengan metadata versi
- Query CLI dasar end-to-end (retrieve → Opus → jawaban)

### Fase 2 — Dual-Model + Validation

- Pipeline Generator + Verifier (loop)
- Validation layer + confidence score
- Hermes sebagai orchestration core

### Fase 3 — SaaS Platform + Multi-Topik

- FastAPI backend + auth + query/ingest API
- **Topic registry + Topic selector** (user pilih Topik; admin tambah Topik baru)
- Next.js dashboard (login, pilih Topik, chat, sources, confidence)
- Logging + feedback

### Fase 4 — Production

- Docker Compose (backend + Chroma + Hermes)



- Cloudflare Tunnel
- (Opsional) cron auto-reindex, engine swap Ollama, subagent lintas-versi

## 11. Risiko & Mitigasi

| Risiko                                      | Dampak                        | Mitigasi                                                       |
|---------------------------------------------|-------------------------------|----------------------------------------------------------------|
| Kualitas parsing .doc 3GPP (tabel kompleks) | Chunk rusak → retrieval buruk | Post-process txt; chunk per-section; QA sampling               |
| Biaya 9router Opus (dual-model = 2x call)   | Cost membengkak               | Verifier pakai model lebih murah jika perlu; cache; rate limit |
| Volume 257 versi → duplikasi tinggi         | Vector DB bengkak, noise      | Default index versi terbaru; versi lama on-demand              |
| Latensi dual-model + loop                   | > target NFR                  | Batasi loop N=2; paralel verifier; streaming                   |
| Akurasi domain (klaim telco salah)          | Kredibilitas                  | Validasi NOZ sebagai domain expert; feedback loop              |
| Lock-in cloud                               | Tdk bisa offline              | Arsitektur engine-agnostic (Ollama swap) sejak awal            |

## 12. Kriteria Sukses MVP

- [ ] Seluruh TS 24.008 (versi terbaru min.) terindeks di ChromaDB
- [ ] Query via dashboard mengembalikan jawaban + confidence + sumber
- [ ] Verifier menolak/flag jawaban tak bersumber (uji dengan query "jebakan")
- [ ] Engine bisa di-swap 9router ↔ Ollama via config tanpa ubah kode
- [ ] Deploy via Docker Compose + akses remote via CF Tunnel
- [ ] Log interaksi tersimpan & dapat ditelusuri

## 13. Lampiran

- **Referensi sumber:** Tri Sumarno, "*Empowering Local AI with Deep Telco Knowledge*" (LinkedIn, 14 Jun 2026)
- **Dokumen terkait:** [Technical Requirements – Reliable AI Research Engine](#) (Tri Sumarno), [3GPP RAG + Hermes Implementation Guide](#) (Hermes Arah)
- **Spec sumber:** 3GPP TS 24.008 — [https://www.3gpp.org/ftp/Specs/archive/24\\_series/24.008](https://www.3gpp.org/ftp/Specs/archive/24_series/24.008)

Dokumen ini disiapkan oleh Hermes Arah untuk kolaborasi NOZ × PT Arah Karya Sinergi · Juni 2026