

Business Requirements Document (BRD)

NORA — Network Oracle for Reliable Answers

Produk	NORA — Network Oracle for Reliable Answers
Tipe	SaaS — Platform AI Research Engine multi-topik untuk standar telekomunikasi
Kolaborasi	NOZ (Telecom Security Research) × PT Arah Karya Sinergi
Versi dokumen	0.2 (Draft)
Tanggal	Juni 2026
Disiapkan oleh	Hermes Arah (ArahKarya)
Status	Draft — menunggu review

1. Ringkasan Eksekutif

NORA adalah **platform AI Research Engine berbasis RAG** yang menjawab pertanyaan teknis seputar standar telekomunikasi dengan jawaban **tergrounded pada spec resmi** — bukan halusinasi. Setiap jawaban disertai **skor keyakinan (confidence)** dan **referensi sumber** (nomor section spec).

NORA dirancang **multi-topik**: tiap **Topik** adalah knowledge base independen (mis. 3GPP TS 24.008, 3GPP TS 23.501, ITU-T, IEEE 802.x, GSMA) dengan metode RAG yang **identik**. User memilih Topik sebelum bertanya, dan sistem mengarahkan query ke knowledge base Topik tersebut. **Topik pertama** yang diimplementasi & terbukti adalah **3GPP TS 24.008** (reference implementation).

Berbeda dengan chatbot LLM umum yang menjawab dari ingatan dan rawan ngarang, NORA memakai arsitektur **RAG + dual-model (Generator → Verifier) + validation layer**, diorkestrasi oleh **NORA Agent Layer** — agent engine mandiri milik NORA (terinspirasi pola Hermes: retrieve → reason → verify → loop + memory per-user), dibangun **multi-tenant** untuk skala SaaS banyak user.

Engine default: API cloud via **9router (Claude Opus generator + Sonnet verifier)**. **Mode lokal:** dapat di-swap ke **Ollama** tanpa mengubah arsitektur — privacy-first opsional.

Proposisi Nilai Inti

1. **Anti-halusinasi** — jawaban wajib bersumber dari spec resmi.
2. **Self-validating** — model kedua memverifikasi jawaban model pertama sebelum dikirim.
3. **Auditable** — setiap jawaban punya confidence score + sumber yang bisa ditelusuri.
4. **Multi-topik & extensible** — satu engine RAG, banyak knowledge base; tambah Topik baru tanpa ubah arsitektur.
5. **Engine-agnostic** — cloud (Opus/Sonnet) atau lokal (Ollama), satu arsitektur.

2. Latar Belakang & Masalah

2.1 Masalah

Engineer telco harus membaca **ribuan halaman** spec 3GPP (mis. TS 24.008 ~600+ halaman, ratusan versi rilis) untuk menjawab satu pertanyaan teknis. Proses ini:

- Lambat dan melelahkan (cari manual di PDF/.doc).
- Rawan salah interpretasi antar versi rilis.
- Tidak ter-dokumentasi (jawaban hilang setelah cari).

2.2 Kenapa bukan ChatGPT/LLM biasa

LLM umum menjawab dari **parametric memory** → sering **halusinasi** pada detail teknis (nomor section, IE, prosedur). Untuk domain regulasi/standar, ini **tidak dapat diterima** — jawaban salah bisa berdampak pada desain jaringan.

2.3 Solusi

NORA mengingesti **spec resmi** (per Topik) ke vector database, lalu menjawab dengan retrieval + sintesis + verifikasi. Sumber jawaban selalu spec asli, bukan ingatan model. Topik pertama yang diimplementasi adalah 3GPP TS 24.008; Topik lain (3GPP spec lain, ITU-T, IEEE, GSMA, dst.) menyusul dengan metode yang sama.

3. Tujuan & Sasaran

3.1 Tujuan Bisnis

- **G1** — Menyediakan tool riset spec telco yang akurat & cepat untuk engineer.
- **G2** — Menjadi showcase kapabilitas RAG-reliable kolab NOZ x ArahKarya.
- **G3** — Arsitektur reusable **multi-topik**: satu engine RAG melayani banyak knowledge base standar telco, mudah ditambah Topik baru.

3.2 Sasaran Terukur (MVP)

ID	Sasaran	Target
OBJ-1	Jawaban tergrounded dengan sumber	100% jawaban menyertakan ≥ 1 sumber
OBJ-2	Latensi query standar	< 10 detik (cloud Opus)
OBJ-3	Coverage knowledge base	Seluruh versi TS 24.008 (257 rilis) terindeks
OBJ-4	Hallucination guard	Jawaban tanpa dukungan konteks → ditolak/flag LOW CONFIDENCE

3.3 Non-Tujuan (Out of Scope MVP)

- **Domain non-telco** (mis. medis, hukum) — fokus standar telekomunikasi dulu. (Multi-**topik** dalam telco justru inti desain MVP.)
- Fine-tuning model.

- Real-time spec update otomatis (Fase lanjut via cron).
- Mobile native app (web dulu).

4. Stakeholder & Pengguna

Peran	Pihak	Kepentingan
Owner produk	NOZ + ArahKarya	Arah produk & strategi
Domain expert	NOZ (Tri Sumarno)	Validasi akurasi telco, sumber spec
Engineering	ArahKarya (Hermes Arah)	Build, deploy, maintain
End user	Network/telco engineer	Query spec, riset teknis

Persona Utama

"**Network Engineer**" — paham telco, butuh jawaban cepat & akurat dari spec. Akses via dashboard web / chat. Tidak mau baca 600 halaman manual.

4A. Konsep Topik (Multi-Topic Knowledge Base)

NORA adalah **engine RAG generik** yang melayani banyak knowledge base. Tiap knowledge base disebut **Topik**.

Definisi

Topik = satu domain/spec standar telco yang punya knowledge base sendiri, collection vector sendiri, namun **berbagi metode RAG yang sama** (chunking section-aware → embed → retrieve → generate → verify → validate).

Struktur Topik

Atribut	Contoh (Topik pertama)	Keterangan
id	3gpp-ts24008	ID teknis unik
nama	3GPP TS 24.008	Nama tampil ke user
deskripsi	Mobile radio interface L3; MM/GMM/CC/SM	Ringkasan domain
collection	ts24008	Nama collection ChromaDB
kb_dir	data/3gpp/24008/txt	Lokasi knowledge base
status	live	live / indexing / planned

Topik Roadmap (ilustrasi)

Topik	Status	Catatan
3GPP TS 24.008	● Live (topik pertama, terbukti E2E)	NAS L3 — MM/GMM/CC/SM
3GPP TS 23.501	○ Planned	5G System Architecture
3GPP TS 33.501	○ Planned	5G Security

Topik	Status	Catatan
ITU-T (seri Q/X)	◦ Planned	Signalling & data networks
IEEE 802.x	◦ Planned	LAN/Wireless
GSMA / O-RAN	◦ Planned	Operator & open RAN

Alur Multi-Topik

1. User **memilih Topik** (dropdown/menu) sebelum bertanya.
2. Query diarahkan ke **collection** milik Topik tersebut.
3. Pipeline RAG identik berjalan dalam scope Topik itu.
4. Admin bisa **menambah Topik baru**: daftarkan metadata → ingest knowledge base → Topik siap dipakai. **Tanpa ubah kode engine.**

Nilai bisnis: satu codebase, banyak produk. Tiap Topik baru = penambahan pasar (segmen engineer berbeda) dengan biaya marginal rendah.

4B. NORA Agent Layer (Engine Orkestrasi Mandiri)

NORA bukan sekadar pipeline RAG statis, melainkan **agent layer mandiri** yang mengorkestrasi reasoning multi-step. Layer ini **milik NORA sendiri** (bukan instance Hermes yang di-embed), terinspirasi pola Hermes Agent namun **dirancang multi-tenant untuk SaaS**.

Kenapa agent layer sendiri (bukan embed Hermes runtime)


Kebutuhan SaaS	Hermes runtime apa adanya	NORA Agent Layer
Banyak user paralel	1 session/profil, stateful	✓ Stateless-per-request, state di DB
Isolasi data per-user	Memory global per profil	✓ Memory & history per-user (Postgres)
Scale horizontal	Proses stateful tunggal	✓ Replica di banyak server
Deploy & pindah server	Bundel runtime berat	✓ Container ringan, DB terpisah

Hermes dipakai sebagai **inspirasi pola + tool pengembangan**, bukan runtime produksi. Yang berharga (loop retrieve→generate→verify→validate, dual-model, memory) di-implementasi sebagai kode NORA yang multi-tenant.

Tanggung jawab Agent Layer

1. **Orkestrasi pipeline**: retrieve → generate (Opus) → verify (Sonnet) → validate → loop jika INVALID.
2. **Memory per-user**: konteks riset & history tersimpan per-user (bukan global).
3. **Reasoning multi-step**: query kompleks (lintas-versi/lintas-Topik) bisa dipecah jadi sub-langkah.
4. **Routing Topik**: arahkan query ke collection Topik aktif.
5. **Stateless & scalable**: tiap request mandiri; state durable di Postgres → aman di-load-balance.

4C. Arsitektur Multi-Tenant (Scale-Ready)



Demo (sekarang, RPi5): Agent layer ringan + ChromaDB + 9router. **Produksi (server proper):** swap ChromaDB→**Qdrant** (vector skala besar), scale replica agent + gateway, Postgres terpisah. **Arsitektur sama, tinggal naik kelas** — tanpa rewrite.

5. Kebutuhan Fungsional

Notasi: **MUST** (wajib MVP), **SHOULD** (sebaiknya), **COULD** (opsional lanjut).

5.1 Knowledge Ingestion

ID	Requirement	Prioritas
FR-ING-001	Sistem MUST mengingesti dokumen spec (.txt hasil convert .doc/.docx 3GPP)	MUST
FR-ING-002	Sistem MUST chunk dokumen berbasis section number (mis. "4.1.2 ATTACH REQUEST"), bukan ukuran fixed	MUST
FR-ING-003	Sistem MUST generate embedding tiap chunk & simpan ke vector DB	MUST
FR-ING-004	Tiap chunk MUST menyimpan metadata: spec ID, versi rilis, section, judul	MUST
FR-ING-005	Sistem SHOULD dukung delta ingestion (hanya versi baru)	SHOULD
FR-ING-006	Sistem COULD generate hash (Keccak-256) per dokumen untuk provenance	COULD

5.2 Query & Retrieval (RAG)

ID	Requirement	Prioritas
		MUST

ID	Requirement	Prioritas
FR-RAG-001	Sistem MUST embed query user lalu retrieve top-K chunk relevan (default K=5, cosine similarity)	
FR-RAG-002	Sistem MUST inject konteks retrieved ke prompt sebelum generate	MUST
FR-RAG-003	Sistem SHOULD dukung filter versi rilis (mis. "jawab berdasarkan R16 saja")	SHOULD
FR-RAG-004	Sistem SHOULD dukung query lintas-versi (bandingkan antar rilis)	SHOULD

5.3 Dual-Model Reasoning (Generator + Verifier)

ID	Requirement	Prioritas
FR-MM-001	Generator (Opus via 9router) MUST hasilkan jawaban awal dari konteks	MUST
FR-MM-002	Verifier (Opus via 9router) MUST cek jawaban vs konteks, klasifikasi: VALID / PARTIAL / INVALID	MUST
FR-MM-003	Jika INVALID, sistem MUST regenerate dengan prompt termodifikasi (loop, maks N=2)	MUST
FR-MM-004	Engine MUST swappable: 9router (default) ↔ Ollama (lokal) via config	MUST

5.4 Validation Layer

ID	Requirement	Prioritas
FR-VL-001	Sistem MUST cross-check klaim jawaban vs chunk sumber	MUST
FR-VL-002	Sistem MUST tolak/flag jawaban dengan klaim tak didukung sumber	MUST
FR-VL-003	Sistem MUST hitung confidence score 0-1	MUST
FR-VL-004	Jika confidence < 0.7, jawaban MUST diberi flag "LOW CONFIDENCE"	MUST

5.5 Output

ID	Requirement	Prioritas
FR-OUT-001	Output MUST terstruktur: <code>{answer, confidence, sources[], verifier_verdict}</code>	MUST
FR-OUT-002	Sources MUST sebut spec ID + versi + section number	MUST
FR-OUT-003	UI SHOULD render jawaban + sumber yang bisa di-expand ke teks asli	SHOULD

5.6 Orkestrasi (NORA Agent Layer — engine mandiri, multi-tenant)

ID	Requirement	Prioritas
FR-ORC-001	Agent Layer MUST jadi orchestration core: retrieve → generate → verify → validate → loop	MUST
FR-ORC-002	Agent Layer MUST dipanggil backend sebagai service/library internal (bukan embed Hermes runtime)	MUST
		MUST

ID	Requirement	Prioritas
FR-ORC-003	Agent Layer MUST stateless-per-request; state durable (memory, history) di Postgres → scalable	
FR-ORC-004	Agent Layer MUST isolasi memory & history per-user (multi-tenant)	MUST
FR-ORC-005	Agent Layer SHOULD reasoning multi-step untuk query kompleks lintas-versi/lintas-Topik	SHOULD
FR-ORC-006	Agent Layer COULD jadwalkan auto-reindex spec (background worker/cron)	COULD

5.7 SaaS Platform (Multi-user)

ID	Requirement	Prioritas
FR-SAAS-001	Sistem MUST punya auth (login/register)	MUST
FR-SAAS-002	Sistem MUST log tiap query (query, konteks, jawaban, hasil validasi)	MUST
FR-SAAS-003	Sistem SHOULD kumpulan feedback user (correct/incorrect/partial)	SHOULD
FR-SAAS-004	Sistem SHOULD pakai feedback untuk perbaiki ranking retrieval & prompt	SHOULD
FR-SAAS-005	Sistem COULD dukung role (admin/engineer/viewer)	COULD

5.8 Topik (Multi-Topic Management)

ID	Requirement	Prioritas
FR-TOP-001	Sistem MUST punya registry Topik (id, nama, deskripsi, collection, kb_dir, status)	MUST
FR-TOP-002	User MUST memilih Topik sebelum query; query MUST diarahkan ke collection Topik tsb	MUST
FR-TOP-003	Sistem MUST isolasi data antar-Topik (retrieval tidak bocor lintas-Topik)	MUST
FR-TOP-004	Admin MUST bisa menambah Topik baru (daftar metadata + ingest) tanpa ubah kode engine	MUST
FR-TOP-005	Sistem SHOULD tampilkan daftar Topik + status (live/indexing/planned) ke user	SHOULD
FR-TOP-006	Sistem COULD dukung query lintas-Topik (mis. cari di 3GPP + ITU-T sekaligus)	COULD

6. Kebutuhan Non-Fungsional

ID	Kategori	Requirement
NFR-001	Performa	Query standar < 10 detik (cloud), < 30 detik (lokal Ollama RPi5)
NFR-002	Skalabilitas	≥ 10 concurrent user (MVP)
NFR-003	Privacy	Mode lokal (Ollama): tidak ada call eksternal; data tetap di host
NFR-004	Reliability	Fallback graceful: 9router down → fallback model / Ollama lokal

ID	Kategori	Requirement
NFR-005	Keamanan	Akses remote via Cloudflare Tunnel (tanpa port terbuka); secret di .env
NFR-006	Maintainability	Containerized (Docker Compose); config-driven engine swap
NFR-007	Auditability	Setiap jawaban traceable ke sumber + tersimpan di log

7. Arsitektur Sistem (High-Level)



Data Flow (1 query)

1. User kirim query (dashboard/Telegram)
2. Backend → Hermes core
3. Hermes: embed query → ChromaDB retrieve top-5 chunk
4. Hermes: bangun prompt [Sys][Context][Query] → Generator (Opus)
5. Hermes: jawaban → Verifier (Opus) → VALID/PARTIAL/INVALID
6. Jika INVALID → loop ke step 4 (maks 2x)
7. Validation layer: cross-check + confidence score
8. Output {answer, confidence, sources} → backend → user
9. Log interaksi + (opsional) feedback

8. Stack Teknologi

Layer	Komponen	Pilihan	Alasan
Frontend	Dashboard	Next.js + Tailwind	SSR, modern, cepat
Backend	API	FastAPI (Python)	Async, cocok untuk AI pipeline
Orkestrasi	Agent Layer	NORA Agent Layer (mandiri, multi-tenant)	Loop verify, memory per-user, scalable
LLM (default)	Cloud	9router → Opus + Sonnet	Generator + Verifier
LLM (swap)	Lokal	Ollama (Llama3.1/Qwen)	Privacy-first opsional
Vector store	DB	ChromaDB (demo) → Qdrant (produksi)	Ringan untuk RPi5; Qdrant untuk skala
State / Auth	DB	PostgreSQL	User, memory, history, log, JWT/session
Embedding	Model	9router Gemini (dim 3072)	Cloud, RAM-aman
Parsing	Doc→Text	LibreOffice headless (sudah teruji)	Convert .doc 3GPP → .txt
Auth	-	JWT / session	Multi-user SaaS
Deploy	Infra	Docker Compose + CF Tunnel	Containerized, remote aman

9. Knowledge Base — Topik #1: 3GPP TS 24.008 (Status Saat Ini)

NORA multi-topik; berikut status **Topik pertama** (reference implementation). Topik lain menyusul dengan struktur sama.

Item	Status
Spec target	TS 24.008 — Mobile radio interface L3; Core network protocols; Stage 3
Cakupan isi	Mobility Mgmt (MM), GPRS MM (GMM), Call Control (CC), Session Mgmt (SM)
Versi terkumpul	257 rilis (R98 v3.0.0 → R18 j-series), 1999–2026
Format mentah	.doc/.docx (per zip) — 778 MB
Format diolah	.txt via LibreOffice headless
Lokasi	<code>~/data/3gpp/24008/{zip,doc,txt}</code>
Status convert	Sedang berjalan (background)

10. Roadmap (Fase)

Fase 1 — RAG Core (Fondasi)

- Chunking per-section + embedding seluruh TS 24.008

- Index ke ChromaDB dengan metadata versi
- Query CLI dasar end-to-end (retrieve → Opus → jawaban)

Fase 2 — Dual-Model + Validation

- Pipeline Generator + Verifier (loop)
- Validation layer + confidence score
- Hermes sebagai orchestration core

Fase 3 — SaaS Platform + Multi-Topik

- FastAPI backend + auth + query/ingest API
- **Topic registry + Topic selector** (user pilih Topik; admin tambah Topik baru)
- Next.js dashboard (login, pilih Topik, chat, sources, confidence)
- Logging + feedback

Fase 4 — Production

- Docker Compose (backend + Chroma + Hermes)
- Cloudflare Tunnel
- (Opsional) cron auto-reindex, engine swap Ollama, subagent lintas-versi

11. Risiko & Mitigasi

Risiko	Dampak	Mitigasi
Kualitas parsing .doc 3GPP (tabel kompleks)	Chunk rusak → retrieval buruk	Post-process txt; chunk per-section; QA sampling
Biaya 9router Opus (dual-model = 2x call)	Cost membengkak	Verifier pakai model lebih murah jika perlu; cache; rate limit
Volume 257 versi → duplikasi tinggi	Vector DB bengkak, noise	Default index versi terbaru; versi lama on-demand
Latensi dual-model + loop	> target NFR	Batasi loop N=2; paralel verifier; streaming
Akurasi domain (klaim telco salah)	Kredibilitas	Validasi NOZ sebagai domain expert; feedback loop
Lock-in cloud	Tdk bisa offline	Arsitektur engine-agnostic (Ollama swap) sejak awal

12. Kriteria Sukses MVP

- [] Seluruh TS 24.008 (versi terbaru min.) terindeks di ChromaDB
- [] Query via dashboard mengembalikan jawaban + confidence + sumber
- [] Verifier menolak/flag jawaban tak bersumber (uji dengan query "jebakan")
- [] Engine bisa di-swap 9router ↔ Ollama via config tanpa ubah kode
- [] Deploy via Docker Compose + akses remote via CF Tunnel
- [] Log interaksi tersimpan & dapat ditelusuri

13. Lampiran

- **Referensi sumber:** Tri Sumarno, "*Empowering Local AI with Deep Telco Knowledge*" (LinkedIn, 14 Jun 2026)
 - **Dokumen terkait:** *Technical Requirements – Reliable AI Research Engine* (Tri Sumarno), *3GPP RAG + Hermes Implementation Guide* (Hermes Arah)
 - **Spec sumber:** 3GPP TS 24.008 — https://www.3gpp.org/ftp/Specs/archive/24_series/24.008
-

Dokumen ini disiapkan oleh Hermes Arah untuk kolaborasi NOZ × PT Arah Karya Sinergi · Juni 2026