

Business Requirements Document (BRD)

NORA — Network Oracle for Reliable Answers

Produk	NORA — Network Oracle for Reliable Answers
Tipe	SaaS — AI Research Engine untuk standar telekomunikasi (3GPP)
Kolaborasi	NOZ (Telecom Security Research) × PT Arah Karya Sinergi
Versi dokumen	0.1 (Draft)
Tanggal	Juni 2026
Disiapkan oleh	Hermes Arah (ArahKarya)
Status	Draft — menunggu review

1. Ringkasan Eksekutif

NORA adalah **AI Research Engine berbasis RAG** yang menjawab pertanyaan teknis seputar standar telekomunikasi 3GPP dengan jawaban **tergrounded pada spec resmi** — bukan halusinasi. Setiap jawaban disertai **skor keyakinan (confidence)** dan **referensi sumber** (nomor section spec).

Berbeda dengan chatbot LLM umum yang menjawab dari ingatan dan rawan ngarang, NORA memakai arsitektur **RAG + dual-model (Generator → Verifier) + validation layer**, diorkestrasi oleh **Hermes Agent** sebagai otak eksekusi.

Engine default: API cloud via **9router (Claude Opus)**. **Mode lokal:** dapat di-swap ke **Ollama** tanpa mengubah arsitektur — privacy-first opsional.

Proposisi Nilai Inti

- Anti-halusinasi** — jawaban wajib bersumber dari spec 3GPP resmi.
- Self-validating** — model kedua memverifikasi jawaban model pertama sebelum dikirim.
- Auditable** — setiap jawaban punya confidence score + sumber yang bisa ditelusuri.
- Engine-agnostic** — cloud (Opus) atau lokal (Ollama), satu arsitektur.

2. Latar Belakang & Masalah

2.1 Masalah

Engineer telco harus membaca **ribuan halaman** spec 3GPP (mis. TS 24.008 ~600+ halaman, ratusan versi rilis) untuk menjawab satu pertanyaan teknis. Proses ini:

- Lambat dan melelahkan (cari manual di PDF/.doc).

- Rawan salah interpretasi antar versi rilis.
- Tidak ter-dokumentasi (jawaban hilang setelah cari).

2.2 Kenapa bukan ChatGPT/LLM biasa

LLM umum menjawab dari **parametric memory** → sering **halusinasi** pada detail teknis (nomor section, IE, prosedur). Untuk domain regulasi/standar, ini **tidak dapat diterima** — jawaban salah bisa berdampak pada desain jaringan.

2.3 Solusi

NORA mengingesti **spec 3GPP resmi** ke vector database, lalu menjawab dengan retrieval + sintesis + verifikasi. Sumber jawaban selalu spec asli, bukan ingatan model.

3. Tujuan & Sasaran

3.1 Tujuan Bisnis

- **G1** — Menyediakan tool riset spec telco yang akurat & cepat untuk engineer.
- **G2** — Menjadi showcase kapabilitas RAG-reliable kolab NOZ × ArahKarya.
- **G3** — Arsitektur reusable yang bisa diperluas ke spec/domain telco lain.

3.2 Sasaran Terukur (MVP)

ID	Sasaran	Target
OBJ-1	Jawaban tergrounded dengan sumber	100% jawaban menyertakan ≥ 1 sumber
OBJ-2	Latensi query standar	< 10 detik (cloud Opus)
OBJ-3	Coverage knowledge base	Seluruh versi TS 24.008 (257 rilis) terindeks
OBJ-4	Hallucination guard	Jawaban tanpa dukungan konteks → ditolak/flag LOW CONFIDENCE

3.3 Non-Tujuan (Out of Scope MVP)

- Multi-domain (non-telco) — single-domain dulu.
- Fine-tuning model.
- Real-time spec update otomatis (Fase lanjut via cron).
- Mobile native app (web dulu).

4. Stakeholder & Pengguna

Peran	Pihak	Kepentingan
Owner produk	NOZ + ArahKarya	Arah produk & strategi
Domain expert	NOZ (Tri Sumarno)	Validasi akurasi telco, sumber spec
Engineering	ArahKarya (Hermes Arah)	Build, deploy, maintain

Peran	Pihak	Kepentingan
End user	Network/telco engineer	Query spec, riset teknis

Persona Utama

"**Network Engineer**" — paham telco, butuh jawaban cepat & akurat dari spec. Akses via dashboard web / chat. Tidak mau baca 600 halaman manual.

5. Kebutuhan Fungsional

Notasi: **MUST** (wajib MVP), **SHOULD** (sebaiknya), **COULD** (opsional lanjut).

5.1 Knowledge Ingestion

ID	Requirement	Prioritas
FR-ING-001	Sistem MUST mengingesti dokumen spec (.txt hasil convert .doc/.docx 3GPP)	MUST
FR-ING-002	Sistem MUST chunk dokumen berbasis section number (mis. "4.1.2 ATTACH REQUEST"), bukan ukuran fixed	MUST
FR-ING-003	Sistem MUST generate embedding tiap chunk & simpan ke vector DB	MUST
FR-ING-004	Tiap chunk MUST menyimpan metadata: spec ID, versi rilis, section, judul	MUST
FR-ING-005	Sistem SHOULD dukung delta ingestion (hanya versi baru)	SHOULD
FR-ING-006	Sistem COULD generate hash (Keccak-256) per dokumen untuk provenance	COULD

5.2 Query & Retrieval (RAG)

ID	Requirement	Prioritas
FR-RAG-001	Sistem MUST embed query user lalu retrieve top-K chunk relevan (default K=5, cosine similarity)	MUST
FR-RAG-002	Sistem MUST inject konteks retrieved ke prompt sebelum generate	MUST
FR-RAG-003	Sistem SHOULD dukung filter versi rilis (mis. "jawab berdasarkan R16 saja")	SHOULD
FR-RAG-004	Sistem SHOULD dukung query lintas-versi (bandingkan antar rilis)	SHOULD

5.3 Dual-Model Reasoning (Generator + Verifier)

ID	Requirement	Prioritas
	Generator (Opus via 9router) MUST hasilkan jawaban awal dari konteks	MUST

ID	Requirement	Prioritas
FR-MM-001		
FR-MM-002	Verifier (Opus via 9router) MUST cek jawaban vs konteks, klasifikasi: VALID / PARTIAL / INVALID	MUST
FR-MM-003	Jika INVALID, sistem MUST regenerate dengan prompt termodifikasi (loop, maks N=2)	MUST
FR-MM-004	Engine MUST swappable: 9router (default) ↔ Ollama (lokal) via config	MUST

5.4 Validation Layer

ID	Requirement	Prioritas
FR-VL-001	Sistem MUST cross-check klaim jawaban vs chunk sumber	MUST
FR-VL-002	Sistem MUST tolak/flag jawaban dengan klaim tak didukung sumber	MUST
FR-VL-003	Sistem MUST hitung confidence score 0-1	MUST
FR-VL-004	Jika confidence < 0.7, jawaban MUST diberi flag "LOW CONFIDENCE"	MUST

5.5 Output

ID	Requirement	Prioritas
FR-OUT-001	Output MUST terstruktur: <code>{answer, confidence, sources[], verifier_verdict}</code>	MUST
FR-OUT-002	Sources MUST sebut spec ID + versi + section number	MUST
FR-OUT-003	UI SHOULD render jawaban + sumber yang bisa di-expand ke teks asli	SHOULD

5.6 Orkestrasi (Hermes Agent — embedded core)

ID	Requirement	Prioritas
FR-ORC-001	Hermes MUST jadi orchestration core: retrieve → generate → verify → validate → loop	MUST
FR-ORC-002	Hermes MUST dipanggil sebagai service/library internal oleh backend (opsi 5a)	MUST
FR-ORC-003	Hermes SHOULD delegate query kompleks lintas-versi ke subagent paralel	SHOULD
FR-ORC-004	Hermes SHOULD simpan konteks riset (memory) per user/sesi	SHOULD
FR-ORC-005	Hermes COULD jadwalkan auto-reindex spec via cron	COULD


5.7 SaaS Platform (Multi-user)

ID	Requirement	Prioritas
FR-SAAS-001	Sistem MUST punya auth (login/register)	MUST
FR-SAAS-002	Sistem MUST log tiap query (query, konteks, jawaban, hasil validasi)	MUST
FR-SAAS-003	Sistem SHOULD kumpulkan feedback user (correct/incorrect/partial)	SHOULD
FR-SAAS-004	Sistem SHOULD pakai feedback untuk perbaiki ranking retrieval & prompt	SHOULD
FR-SAAS-005	Sistem COULD dukung role (admin/engineer/viewer)	COULD

6. Kebutuhan Non-Fungsional

ID	Kategori	Requirement
NFR-001	Performa	Query standar < 10 detik (cloud), < 30 detik (lokal Ollama RPI5)
NFR-002	Skalabilitas	≥ 10 concurrent user (MVP)
NFR-003	Privacy	Mode lokal (Ollama): tidak ada call eksternal; data tetap di host
NFR-004	Reliability	Fallback graceful: 9router down → fallback model / Ollama lokal
NFR-005	Keamanan	Akses remote via Cloudflare Tunnel (tanpa port terbuka); secret di .env
NFR-006	Maintainability	Containerized (Docker Compose); config-driven engine swap
NFR-007	Auditability	Setiap jawaban traceable ke sumber + tersimpan di log

7. Arsitektur Sistem (High-Level)



Data Flow (1 query)

1. User kirim query (dashboard/Telegram)
2. Backend → Hermes core
3. Hermes: embed query → ChromaDB retrieve top-5 chunk
4. Hermes: bangun prompt [Sys][Context][Query] → Generator (Opus)
5. Hermes: jawaban → Verifier (Opus) → VALID/PARTIAL/INVALID
6. Jika INVALID → loop ke step 4 (maks 2x)
7. Validation layer: cross-check + confidence score

8. Output {answer, confidence, sources} → backend → user
9. Log interaksi + (opsional) feedback

8. Stack Teknologi

Layer	Komponen	Pilihan	Alasan
Frontend	Dashboard	Next.js + Tailwind	SSR, modern, cepat
Backend	API	FastAPI (Python)	Async, cocok untuk AI pipeline
Orkestrasi	Agent	Hermes Agent (embedded)	Memory, skills, subagent, loop
LLM (default)	Cloud	9router → Claude Opus	Reasoning kuat untuk verifikasi
LLM (swap)	Lokal	Ollama (Llama3.1/Qwen)	Privacy-first opsional
Vector store	DB	ChromaDB	Ringan, embedded, cocok RPi5/VPS
Embedding	Model	9router embed / nomic-embed-text	Sesuai mode cloud/lokal
Parsing	Doc→Text	LibreOffice headless (sudah teruji)	Convert .doc 3GPP → .txt
Auth	-	JWT / session	Multi-user SaaS
Deploy	Infra	Docker Compose + CF Tunnel	Containerized, remote aman

9. Knowledge Base (Status Saat Ini)

Item	Status
Spec target	TS 24.008 — Mobile radio interface L3; Core network protocols; Stage 3
Cakupan isi	Mobility Mgmt (MM), GPRS MM (GMM), Call Control (CC), Session Mgmt (SM)
Versi terkumpul	257 rilis (R98 v3.0.0 → R18 j-series), 1999–2026
Format mentah	.doc/.docx (per zip) — 778 MB
Format diolah	.txt via LibreOffice headless
Lokasi	<code>~/data/3gpp/24008/{zip,doc,txt}</code>
Status convert	Sedang berjalan (background)

10. Roadmap (Fase)

Fase 1 — RAG Core (Fondasi)

- Chunking per-section + embedding seluruh TS 24.008
- Index ke ChromaDB dengan metadata versi
- Query CLI dasar end-to-end (retrieve → Opus → jawaban)

Fase 2 — Dual-Model + Validation

- Pipeline Generator + Verifier (loop)

- Validation layer + confidence score
- Hermes sebagai orchestration core

Fase 3 — SaaS Platform

- FastAPI backend + auth + query/ingest API
- Next.js dashboard (login, chat, sources, confidence)
- Logging + feedback

Fase 4 — Production

- Docker Compose (backend + Chroma + Hermes)
- Cloudflare Tunnel
- (Opsional) cron auto-reindex, engine swap Ollama, subagent lintas-versi

11. Risiko & Mitigasi

Risiko	Dampak	Mitigasi
Kualitas parsing .doc 3GPP (tabel kompleks)	Chunk rusak → retrieval buruk	Post-process txt; chunk per-section; QA sampling
Biaya 9router Opus (dual-model = 2x call)	Cost membengkak	Verifier pakai model lebih murah jika perlu; cache; rate limit
Volume 257 versi → duplikasi tinggi	Vector DB bengkak, noise	Default index versi terbaru; versi lama on-demand
Latensi dual-model + loop	> target NFR	Batasi loop N=2; paralel verifier; streaming
Akurasi domain (klaim telco salah)	Kredibilitas	Validasi NOZ sebagai domain expert; feedback loop
Lock-in cloud	Tdk bisa offline	Arsitektur engine-agnostic (Ollama swap) sejak awal

12. Kriteria Sukses MVP

- [] Seluruh TS 24.008 (versi terbaru min.) terindeks di ChromaDB
- [] Query via dashboard mengembalikan jawaban + confidence + sumber
- [] Verifier menolak/flag jawaban tak bersumber (uji dengan query "jebakan")
- [] Engine bisa di-swap 9router ↔ Ollama via config tanpa ubah kode
- [] Deploy via Docker Compose + akses remote via CF Tunnel
- [] Log interaksi tersimpan & dapat ditelusuri

13. Lampiran

- **Referensi sumber:** Tri Sumarno, "*Empowering Local AI with Deep Telco Knowledge*" (LinkedIn, 14 Jun 2026)

- **Dokumen terkait:** [Technical Requirements – Reliable AI Research Engine](#) (Tri Sumarno), [3GPP RAG + Hermes Implementation Guide](#) (Hermes Arah)
 - **Spec sumber:** 3GPP TS 24.008 — https://www.3gpp.org/ftp/Specs/archive/24_series/24.008
-

Dokumen ini disiapkan oleh Hermes Arah untuk kolaborasi NOZ × PT Arah Karya Sinergi · Juni 2026