



*"Reliable answers, grounded in the spec."*

Platform AI Research Engine Multi-Topik untuk Standar Telekomunikasi

Topik #1: 3GPP TS 24.008 · Proposal Produk & Arsitektur · Juni 2026

## MASALAH

# Engineer telco tenggelam dalam ribuan halaman spec

Standar 3GPP adalah "kitab hukum" jaringan seluler — resmi, wajib dipatuhi, dan sangat tebal. Mencari satu jawaban teknis bisa makan berjam-jam.



### Volume masif

TS 24.008 saja punya 257 versi rilis, masing-masing ratusan halaman. Cari manual = lambat.



### LLM umum ngarang

ChatGPT menjawab dari ingatan — sering halusinasi pada detail teknis (section, IE, prosedur).



### Tak terlacak

Jawaban tanpa sumber tidak bisa diverifikasi. Untuk standar regulasi, ini tidak dapat diterima.

## SOLUSI

# NORA — jawaban yang selalu bersumber dari spec resmi

Tanya pakai bahasa biasa. NORA mencari spec relevan, menyusun jawaban, **memverifikasinya dengan model kedua**, lalu mengembalikan jawaban + tingkat keyakinan + sumber.

- ✓ **Anti-halusinasi** — jawaban wajib tergrounded pada spec resmi (RAG)
- ✓ **Self-validating** — model Verifier mengecek jawaban Generator sebelum dikirim
- ✓ **Auditable** — tiap jawaban punya confidence score + referensi section spec
- ✓ **Multi-topik** — satu engine, banyak knowledge base (3GPP, ITU-T, IEEE, ...)
- ✓ **Engine-agnostic** — cloud (9router) atau lokal (Ollama), satu arsitektur

# Satu pertanyaan masuk, satu jawaban terverifikasi keluar



## INPUT — Pertanyaan natural

*"Jelaskan prosedur Attach Request di TS 24.008 dan bandingkan dengan Registration di 5G."*



## OUTPUT — Jawaban terstruktur

```
{  
  "answer": "Prosedur dimulai saat MS...",  
  "confidence": 0.87,  
  "sources": ["TS 24.008 §4.7.3"]  
}
```

Bedanya dengan chatbot biasa: NORA **menunjuk sumber** dan **menolak menjawab** jika spec tidak mendukung.

## PIPELINE

# RAG + Dual-Model + Validasi



Jika Verifier menilai **INVALID**, sistem otomatis mengulang (regenerate) — loop verifikasi inilah inti keandalan NORA.

# Hermes Agent sebagai otak orkestrasi

|                 |                                |                                                                        |
|-----------------|--------------------------------|------------------------------------------------------------------------|
| <b>FRONTEND</b> | <b>Next.js Dashboard</b>       | Login, chat query, lihat jawaban + sumber + confidence                 |
| <b>BACKEND</b>  | <b>FastAPI</b>                 | REST API — auth, query, ingest; memanggil Hermes core                  |
| <b>OTAK</b>     | <b>Hermes Agent (embedded)</b> | Orkestrasi: retrieve → generate → verify → validate → loop             |
| <b>ENGINE</b>   | <b>9router · Opus + Sonnet</b> | Generator (Opus) + Verifier (Sonnet) — swap ke Ollama lokal            |
| <b>TOPIK</b>    | <b>Topic Registry</b>          | Multi-topik: 1 collection per Topik (3GPP TS 24.008, ITU-T, IEEE, ...) |
| <b>DATA</b>     | <b>ChromaDB + Gemini embed</b> | Vector store per Topik; embedding Gemini via 9router (dim 3072)        |

## 3GPP TS 24.008 — terindeks penuh

Topik pertama yang live. Mobile radio interface Layer 3: Mobility Management, GPRS MM, Call Control, Session Management. Seluruh sejarah rilis R98 → R18. Topik lain (ITU-T, IEEE, GSMA) menyusul dengan metode sama.

**257**

versi rilis terkumpul

**1999-  
2026**

rentang tahun spec

**778<sub>MB</sub>**

dokumen sumber resmi

**100%**

lokal & auditable

MULTI-TOPIK

# Satu engine RAG, banyak knowledge base

NORA bukan terkunci ke satu spec. Tiap **Topik** = knowledge base standar telco independen dengan collection sendiri, tapi metode RAG identik. User pilih Topik → bertanya. Nambah Topik baru: registrasi + ingest, **tanpa ubah kode engine**.

| Topik              | Status                | Domain                      |
|--------------------|-----------------------|-----------------------------|
| 3GPP TS 24.008     | ● Live (terbukti E2E) | NAS L3 — MM / GMM / CC / SM |
| 3GPP TS 23.501     | ○ Planned             | 5G System Architecture      |
| 3GPP TS 33.501     | ○ Planned             | 5G Security                 |
| ITU-T (seri Q / X) | ○ Planned             | Signalling & data networks  |
| IEEE 802.x         | ○ Planned             | LAN / Wireless              |
| GSMA / O-RAN       | ○ Planned             | Operator & Open RAN         |



PEMBEDA

# Pipeline statis vs NORA berorkestrasi

| Aspek             | Pendekatan dasar            | NORA + Hermes                   |
|-------------------|-----------------------------|---------------------------------|
| Keandalan jawaban | Single model, rawan ngarang | Generator + Verifier + validasi |
| Sumber            | Sering tanpa referensi      | Selalu sebut section spec       |
| Antarmuka         | CLI / script manual         | Dashboard web + (opsi) Telegram |
| Update spec       | Manual                      | Terjadwal via cron Hermes       |
| Engine            | Terkunci satu model         | Cloud ↔ lokal, swappable        |
| Privacy           | Lokal                       | Lokal penuh (mode Ollama)       |

# Stack ringan, jalan di Raspberry Pi 5



## Engine AI

9router → Claude Opus (Generator) + Sonnet (Verifier). Swap ke Ollama (Llama3.1/Qwen) untuk lokal penuh.



## Vector & Embedding

ChromaDB embedded (1 collection per Topik) + embedding Gemini via 9router (dim 3072). RAM RPi5 aman — embedding di cloud.



## Orkestrasi

Hermes Agent — memory, skills, subagent paralel, cron auto-reindex.



## Aplikasi

FastAPI backend + Next.js dashboard. Multi-user, auth, logging.



## Deploy

Docker Compose di RPi5 8GB. Reproducible, ringan.



## Akses Aman

Cloudflare Tunnel — remote tanpa membuka port. Akses dari mana saja.

## ROADMAP

# Dari fondasi RAG ke produk SaaS

### FASE 1

#### RAG Core

- › Chunk per-section
- › Embed 257 versi
- › Index ChromaDB
- › Query CLI dasar

### FASE 2

#### Dual-Model

- › Generator + Verifier
- › Validation + confidence
- › Hermes orkestrasi
- › Loop verifikasi

### FASE 3

#### SaaS + Multi-Topik

- › FastAPI + auth
- › Topic registry + selector
- › Next.js dashboard
- › Logging + feedback

### FASE 4

#### Production

- › Docker Compose
- › Cloudflare Tunnel
- › Cron auto-reindex
- › Monitoring

Knowledge base sudah terkumpul. Fase 1 siap dieksekusi.

# Mari bangun NORA.

*"Reliable answers, grounded in the spec."*

Topik #1 (3GPP TS 24.008) terbukti E2E · Arsitektur multi-topik · Fase 2 siap jalan.

Platform telco AI yang akurat, terverifikasi, dan dapat ditelusuri — banyak Topik, satu engine.

DISIAPKAN OLEH

**PT Arah Karya Sinergi**