

Product Requirements Document (PRD)

NORA — Network Oracle for Reliable Answers

Produk	NORA — Network Oracle for Reliable Answers
Tipe	SaaS — Platform AI Research Engine multi-topik untuk standar telekomunikasi
Kolaborasi	NOZ × PT Arah Karya Sinergi
Versi	0.2 (Draft)
Tanggal	Juni 2026
Disiapkan oleh	Hermes Arah (ArahKarya)
Dokumen induk	BRD-NORA.md

1. Tujuan Dokumen

PRD ini menjabarkan **bagaimana NORA bekerja sebagai produk**: fitur detail, alur pengguna, kontrak API, perilaku tiap layer, desain UI, dan kriteria penerimaan (acceptance criteria). PRD adalah jembatan antara BRD (kenapa & apa) dan implementasi teknis (kode).

Cakupan rilis: Dokumen ini mendefinisikan **MVP (Fase 1-3)** + arahan Fase 4. Fitur di luar MVP ditandai **[POST-MVP]**.

2. Ringkasan Produk

NORA adalah **platform multi-topik**: user memilih **Topik** (knowledge base standar telco, mis. 3GPP TS 24.008) lalu mengirim **pertanyaan teknis** dalam bahasa natural. Sistem mencari potongan spec relevan **dalam Topik tersebut**, menyusun jawaban via LLM, **memverifikasi jawaban dengan model kedua**, lalu mengembalikan **jawaban + confidence + sumber**. Semua diorkestrasi oleh **NORA Agent Layer** (engine mandiri, multi-tenant). Topik pertama yang live & terbukti: **3GPP TS 24.008**.

Satu kalimat: "Pilih topik standar telco, tanya pakai bahasa biasa, dapat jawaban akurat yang bisa ditelusuri ke spec resmi."

3. Persona & User Stories

3.1 Persona

Persona	Deskripsi	Kebutuhan
Engineer (primary)	Network/telco engineer, paham domain, butuh jawaban cepat	Query akurat + sumber, riset lintas-versi
Researcher (NOZ)	Domain expert, validasi akurasi	Lihat sumber asli, beri feedback, audit
Admin	Operator platform (ArahKarya)	Kelola user, ingest spec, monitor usage

3.2 User Stories

ID	Sebagai	Saya ingin	Sehingga
US-01	Engineer	bertanya prosedur spec pakai bahasa natural	tidak perlu baca 600 halaman manual
US-02	Engineer	melihat sumber (section spec) tiap jawaban	bisa verifikasi & percaya jawaban
US-03	Engineer	tahu seberapa yakin sistem (confidence)	tahu kapan harus cek manual
US-04	Engineer	membandingkan prosedur antar versi rilis	paham evolusi spec (R98 vs R16)
US-05	Researcher	menandai jawaban salah/benar	sistem belajar & makin akurat
US-06	Admin	meng-ingest spec baru	knowledge base selalu update
US-07	Admin	melihat log query & usage	monitor & audit pemakaian
US-08	Engineer	mengakses dari mana saja (web/chat)	tidak terikat ke terminal/server
US-09	Engineer	memilih Topik (mis. 3GPP TS 24.008) sebelum bertanya	jawaban fokus pada domain spec yang saya butuhkan
US-10	Admin	menambah Topik baru (registrasi + ingest knowledge base)	platform berkembang ke standar telco lain tanpa ganti kode

4. Fitur Produk (Feature Breakdown)

F0 — Topic Selector & Registry (CORE)

Deskripsi: User memilih **Topik** (knowledge base) sebelum bertanya; tiap Topik punya collection sendiri. Admin mengelola registry Topik.

Perilaku:

1. Saat masuk, user lihat daftar Topik tersedia + status (live/indexing/planned).
2. User pilih satu Topik aktif (mis. "3GPP TS 24.008").
3. Semua query berikutnya diarahkan ke collection Topik tersebut (isolasi data).
4. Admin bisa **registrasi Topik baru**: isi metadata (id, nama, deskripsi, collection, kb_dir) → ingest → status **live**.

Acceptance Criteria:

- [] AC-F0-1: Daftar Topik tampil dengan nama + deskripsi + status.
- [] AC-F0-2: User wajib pilih Topik aktif sebelum query; query memakai collection Topik tsb.
- [] AC-F0-3: Retrieval tidak bocor lintas-Topik (isolasi terverifikasi).
- [] AC-F0-4: Admin bisa tambah Topik baru tanpa ubah kode engine.
- [] AC-F0-5: **[POST-MVP]** Query lintas-Topik (gabung beberapa Topik).

F1 — Ask / Query Engine (CORE)

Deskripsi: Dalam Topik aktif, user mengirim pertanyaan; NORA menjawab dengan pipeline RAG + dual-model.

Perilaku:

1. User input pertanyaan (teks bebas) **dalam Topik aktif**.
2. Sistem retrieve top-5 chunk relevan dari collection Topik.
3. Generator (Opus) menyusun jawaban dari konteks.
4. Verifier (Sonnet) menilai: VALID / PARTIAL / INVALID.
5. Jika INVALID → regenerate (maks 2x).
6. Validation layer hitung confidence + cek klaim.
7. Tampilkan jawaban + confidence badge + sumber expandable.

Acceptance Criteria:

- [] AC-F1-1: Setiap jawaban menyertakan ≥ 1 sumber (spec ID + versi + section).
- [] AC-F1-2: Confidence < 0.7 → badge "LOW CONFIDENCE" tampil.
- [] AC-F1-3: Query tanpa konteks relevan → "Tidak ditemukan di spec" (bukan ngarang).
- [] AC-F1-4: Verdict verifier tampil (VALID/PARTIAL/INVALID).

F2 — Source Inspector

Deskripsi: User klik sumber → lihat teks chunk asli dari spec.

Acceptance Criteria:

- [] AC-F2-1: Tiap sumber bisa di-expand menampilkan teks chunk asli.
- [] AC-F2-2: Metadata tampil: spec ID, versi rilis, section number, judul section.

F3 — Version Filter & Cross-Version Compare

Deskripsi: User batasi jawaban ke versi tertentu, atau bandingkan antar versi.

Acceptance Criteria:

- [] AC-F3-1: Dropdown pilih versi (default: terbaru).
- [] AC-F3-2: **[POST-MVP]** Mode "bandingkan" → 2 versi side-by-side via subagent paralel.

F4 — Knowledge Ingestion (Admin)

Deskripsi: Admin ingest spec (.txt) → chunk per-section → embed → index.

Acceptance Criteria:

- [] AC-F4-1: Upload/point ke folder .txt → otomatis chunk per-section.
- [] AC-F4-2: Tiap chunk simpan metadata (spec, versi, section).
- [] AC-F4-3: Progress ingest terlihat (X/Y chunk terindeks).
- [] AC-F4-4: [POST-MVP] Delta ingestion (skip versi yang sudah terindeks).

F5 — Auth & Multi-User

Deskripsi: Login/register, sesi per-user, role.

Acceptance Criteria:

- [] AC-F5-1: Register + login (email/password, JWT).
- [] AC-F5-2: Query history tersimpan per-user.
- [] AC-F5-3: [POST-MVP] Role admin/engineer/viewer.

F6 — Feedback Loop

Deskripsi: User tandai jawaban correct/incorrect/partial.

Acceptance Criteria:

- [] AC-F6-1: Tombol feedback di tiap jawaban.
- [] AC-F6-2: Feedback tersimpan terkait query+jawaban+sumber.
- [] AC-F6-3: [POST-MVP] Feedback dipakai re-rank retrieval.

F7 — Query Log & Audit (Admin)

Acceptance Criteria:

- [] AC-F7-1: Semua query tercatat (query, konteks, jawaban, verdict, confidence, user, waktu).
- [] AC-F7-2: Admin bisa filter & telusuri log.

F8 — Engine Swap (Config)

Deskripsi: Swap engine cloud (9router Opus) ↔ lokal (Ollama) via config, tanpa ubah kode.

Acceptance Criteria:


- [] AC-F8-1: Env `NORA_ENGINE=9router|ollama` mengganti adapter.
- [] AC-F8-2: Pipeline identik untuk kedua mode.

F9 — [POST-MVP] Telegram Gateway

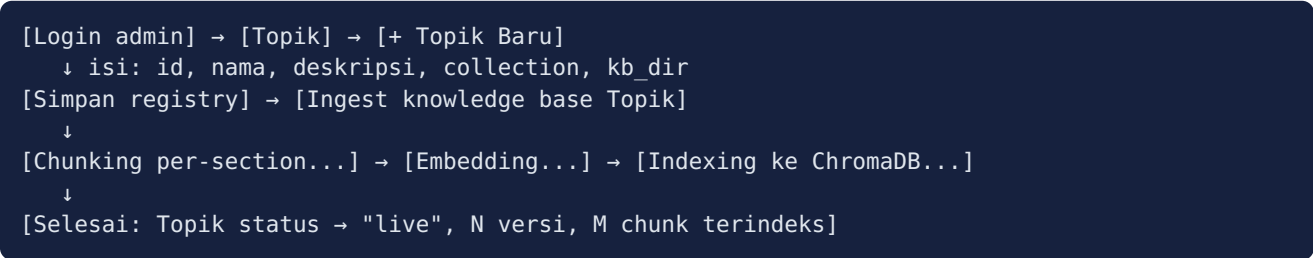
Deskripsi: Query NORA via Telegram lewat Hermes gateway.

5. User Flow

5.1 Flow Utama — Ask a Question



5.2 Flow Admin — Tambah Topik & Ingest




6. Desain UI (Dashboard)

6.1 Halaman

Halaman	Isi
Login/Register	Form auth
Topik (selector)	Daftar Topik + status; pilih Topik aktif
Ask (utama)	Topik aktif (badge), input query besar, riwayat chat, hasil jawaban
Answer view	Jawaban + confidence + verdict + sources expandable + feedback
History	Daftar query sebelumnya per-user (dengan Topik)
Knowledge Base / Topik (admin)	Registry Topik, tambah Topik, status spec terindeks, tombol ingest
Logs (admin)	Tabel query log + filter

6.2 Komponen Kunci — Answer Card



```
Sumber:
  ▶ TS 24.008 v16.5.0 §4.7.3 (GMM Attach)  [+]
  ▶ TS 24.008 v16.5.0 §4.7.3.1           [+]

Akurat? [👍] [👎] [~]
```

7. Kontrak API (Backend)

7.1 GET /api/topics

Daftar Topik tersedia.

```
{
  "topics": [
    {
      "id": "3gpp-ts24008",
      "nama": "3GPP TS 24.008",
      "deskripsi": "Mobile radio interface L3; MM/GMM/CC/SM",
      "collection": "ts24008",
      "status": "live",
      "versions_indexed": 257
    }
  ]
}
```

7.2 POST /api/query

Request:

```
{
  "topic": "3gpp-ts24008",           // WAJIB – Topik aktif
  "query": "Jelaskan prosedur Attach Request di TS 24.008",
  "version_filter": "16.5.0",        // optional, default: latest
  "top_k": 5                         // optional, default 5
}
```

Response:

```
{
  "topic": "3gpp-ts24008",
  "answer": "Prosedur Attach Request dimulai saat MS mengirim...",
  "confidence": 0.87,
  "verifier_verdict": "VALID",
  "sources": [
    {
      "spec": "TS 24.008",
      "version": "16.5.0",
      "section": "4.7.3",
      "title": "GPRS attach procedure",
      "chunk_text": "..."
    }
  ],
  "regeneration_count": 0,
}
```

```
{
  "query_id": "q_abc123"
}
```

7.3 `POST /api/topics` (admin) — registrasi Topik baru

```
{
  "id": "3gpp-ts23501",
  "nama": "3GPP TS 23.501",
  "deskripsi": "5G System Architecture",
  "collection": "ts23501",
  "kb_dir": "/data/3gpp/23501/txt"
}
```

→ { "status": "registered", "topic": "3gpp-ts23501" }

7.4 `POST /api/ingest` (admin)

```
{ "topic": "3gpp-ts24008", "source_path": "/data/3gpp/24008/txt" }
```

→ { "status": "indexing", "job_id": "...", "total_files": 257 }

7.5 `POST /api/feedback`

```
{ "query_id": "q_abc123", "rating": "correct" }
```

7.6 `GET /api/history` • `GET /api/logs` (admin) • `POST /api/auth/login|register`

8. Spesifikasi Layer (Behavior Detail)

8.1 Chunking (Ingest)

- **Strategi:** split berbasis **section number** regex (mis. `^\d+(\.\d+)*\s+[A-Z]`).
- **Fallback:** jika section terlalu besar (>800 token), sub-split dengan overlap 50 token.
- **Metadata wajib:** `topic`, `spec_id`, `version`, `section`, `section_title`, `source_file` .

8.2 Retrieval

- Tentukan **collection** dari Topik aktif → embed query → cosine similarity → top-K (default 5) **dalam collection itu**.
- Filter metadata `version` jika `version_filter` diberikan.
- Isolasi Topik: retrieval tidak pernah lintas-collection (kecuali mode lintas-Topik `[POST-MVP]`).

8.3 Prompt (Generator)

```
[System] Kamu asisten teknis 3GPP. Jawab HANYA berdasarkan konteks.
        Jika konteks tidak cukup, katakan tidak ditemukan. Sertakan section.
[Context] {top_k chunks}
[Query] {user query}
```

8.4 Verifier

```
[System] Nilai apakah jawaban didukung penuh oleh konteks.  
        Output: VALID | PARTIAL | INVALID + alasan singkat.  
[Context] {chunks} [Answer] {generated answer}
```

- INVALID → loop regenerate (maks 2). PARTIAL → tetap kirim + flag.

8.5 Validation & Confidence

- Confidence = fungsi dari: verdict verifier + skor similarity rata-rata top-K + ada/tidaknya klaim tak bersumber.
- **< 0.7** → flag LOW CONFIDENCE.

8.6 NORA Agent Layer (Orkestrasi)

- Agent layer **mandiri** (kode NORA, bukan embed Hermes runtime) dipanggil backend sebagai service/library.
- Menjalankan: retrieve → generate → verify → validate → loop.
- **Multi-tenant**: stateless-per-request, memory & history per-user di Postgres → scalable.
- **[POST-MVP]** reasoning multi-step untuk cross-version/cross-Topik; background worker auto-reindex.

9. Acceptance Criteria — Rilis MVP (Definition of Done)

- [] DoD-1: Topik #1 (3GPP TS 24.008) terindeks penuh di ChromaDB sebagai collection tersendiri.
- [] DoD-2: **POST /api/query** dengan **topic** mengembalikan jawaban + confidence + sumber valid.
- [] DoD-3: Verifier menolak/flag jawaban tak bersumber (uji 5 query jebakan).
- [] DoD-4: Dashboard: login → pilih Topik → ask → answer card lengkap → feedback.
- [] DoD-5: Engine swap 9router ↔ Ollama via env var berhasil tanpa ubah kode.
- [] DoD-6: Query log tersimpan (termasuk Topik) & dapat ditelusuri admin.
- [] DoD-7: Admin bisa registrasi + ingest Topik baru tanpa ubah kode engine.
- [] DoD-8: Deploy Docker Compose + akses via Cloudflare Tunnel.

10. Metrik Keberhasilan (Product Metrics)

Metrik	Target MVP
Jawaban dengan sumber	100%
Latensi median query	< 10 dtk (cloud)
Akurasi (uji domain NOZ, sampel 30 Q)	≥ 85% VALID
Hallucination rate (query jebakan)	0% lolos tanpa flag
Uptime	≥ 99%

11. Dependensi & Asumsi

- 9router tersedia & punya kuota Opus + Sonnet (Generator + Verifier = 2 call/query).
- Embedding tersedia (9router Gemini `gemini-embedding-001` , atau lokal fastembed).
- Knowledge base Topik (.txt) sudah ter-convert.
- **NORA Agent Layer** = kode internal NORA (bukan dependensi Hermes runtime).
- ChromaDB (demo) / Qdrant (produksi) + PostgreSQL (state) + Docker tersedia di RPi5/VPS.

12. Open Questions

Status: Seluruh open question telah diputuskan (Juni 2026).

#	Pertanyaan	
Q1	Embedding pakai 9router atau lokal?	9router Gemini (<code>gemini/gemini-embedding-001</code> , dim 3072) — cloud, ringan di RPi5 (RAM aman, tidak OOM). Mode lokal (fastembed) tetap tersedia via <code>NORA_EMBED_BACKEND=local</code>
Q2	Verifier pakai model apa?	Claude Sonnet (<code>cc/claude-sonnet-4-6</code>) via 9router — lebih hemat dari Opus untuk verifikasi
Q3	Index berapa versi?	Semua 257 versi TS 24.008 (R98 → R18) dengan metadata versi
Q4	Branding	Lihat §13 Branding — palet Navy <code>#0F3460</code> + Teal <code>#16C79A</code> , tagline " <i>Reliable answers, grounded in the spec.</i> "
Q5	Target deploy	Raspberry Pi 5 (8GB) — Docker Compose + Cloudflare Tunnel

Konfigurasi Model Final

Peran	Model	Provider
Generator	<code>cc/claude-opus-4-8</code> (Opus)	9router
Verifier	<code>cc/claude-sonnet-4-6</code> (Sonnet)	9router
Embedding	<code>gemini/gemini-embedding-001</code> (dim 3072)	9router (Gemini)
Swap lokal	Llama3.1 / Qwen (gen) · fastembed (embed)	Ollama / lokal

Dokumen ini disiapkan oleh Hermes Arah untuk kolaborasi NOZ × PT Arah Karya Sinergi · Juni 2026

13. Branding

13.1 Identitas

Elemen	Spesifikasi
Nama	NORA — Network Oracle for Reliable Answers
Tagline	" <i>Reliable answers, grounded in the spec.</i> "
Tagline (ID)	" <i>Tanya spec, jawab terverifikasi.</i> "

Elemen	Spesifikasi
Positioning	Asisten riset senior yang teliti — percaya diri tapi selalu menunjuk sumber

13.2 Palet Warna

Peran	Warna	Hex	Penggunaan
Primary	Deep Navy	#0F3460	Header, brand, tombol utama
Accent	Teal/Mint	#16C79A	Highlight, "verified", confidence tinggi
Dark BG	Midnight	#16213E	Background mode gelap
Alert	Amber	#F0A500	Flag LOW CONFIDENCE
Danger	Red	#C0392B	Verdict INVALID

13.3 Typography

- **Heading:** Space Grotesk / Sora (modern, techy)
- **Body:** Inter (clean, readable)
- **Mono:** JetBrains Mono / DejaVu Sans Mono (untuk section number & kode spec)

13.4 Logo Concept

Monogram **N** dengan stroke diagonal berbentuk gelombang sinyal (telco) — atau lingkaran orbit/oracle dengan node N di tengah. Warna Navy + aksen Teal. (Aset SVG final menyusul.)